

Introduction

Stratégie de Data Engineering BottleNeck

Automatisation et industrialisation du pipeline de données pour le
marchand de vin

Pascal DUVAL

AI/ML Engineer



Objectifs du Projet d'Automatisation

Transformer l'analyse ponctuelle de Stéphane en un système industriel fiable

01

Centralisation des flux
provenant des systèmes CMS
(Vente en ligne) et ERP
(Gestion de stock)

02

Calcul automatisé du chiffre
d'affaires par produit et du
CA global de l'entreprise

03

Segmentation prédictive pour
identifier les vins premium et
ordinaires via des méthodes
statistiques

04

Distribution mensuelle de
rapports aux responsables
produits Laure et Maria

Opérations

Calendrier de Production Mensuel

Planification stricte pour assurer la disponibilité des rapports

15


Date fixée pour le déclenchement automatique du workflow complet.

09:00

Exécution matinale pour livraison immédiate aux responsables produits.

Sources de Données et Réconciliation

Intégration des fichiers sources via la clé de liaison unique



Pipeline de Data Transformation

La méthode de Stéphane à industrialiser étape par étape



Nettoyage

Suppression des valeurs manquantes et dédoublonnage pour obtenir des clés primaires uniques.

Jointure

Fusion des données ERP et Web via le fichier intermédiaire de liaison.

Agrégation

Calcul du chiffre d'affaires par bouteille et sommation du CA total.

Segmentation



Classification des vins via l'application du z-score sur les prix.

Industrialisation avec Kestra

Choix technique de la DSI pour la gestion de l'automatisation


Simplicité

Solution préconisée par la DSI pour sa prise en main rapide et sa modularité.



Planification

Gestion native du calendrier d'exécution mensuel.



Orchestration

Enchaînement automatique des tâches de transformation et de test.

» Fichier ERP

- » Source ERP / stock / catalogue interne avec 825 lignes et 825 product_id distincts Champs clés : product_id, onsale_web, price, stock_quantity, stock_status

» Fichier Web

- » Export WordPress / WooCommerce contenant 716 lignes de type product et 714 lignes de type attachment 83 lignes sans post_type — export large, pas fichier produit propre
- » Champs présents : sku, post_title, post_status, total_sales, average_rating, dates, champs techniques

» Conclusion rapide

- » ERP et liaison alignés sur 825 produits;
- » fichier web est plus large et nécessite filtrage

Lecture sémantique des fichiers

Comparaison des trois fichiers: ERP interne, table de liaison et export web; points clés sur structure, doublons et nature des enregistrements

Lien logique des fichiers

Clarifie le rôle de chaque identifiant: product_id ERP interne, id_web comme clé de passage, sku pour l'identification web

- » Fichier_erp.product_id correspond à l'identifiant interne ERP
- » fichier_liaison.product_id connecte au product_id ERP
- » fichier_liaison.id_web est la clé de passage vers le web
- » Fichier_web identifie les produits par sku
- » Presque tous les id_web de la table de liaison retrouvent un sku dans le fichier web
- » Le product_id ERP ne correspond pas directement au sku web
- » Conclusion: *la table de liaison est **indispensable** pour l'intégrité des correspondances*

Anomalies détectées dans la liaison - part1

Synthèse des points suspects identifiés dans fichier_liaison.xlsx et concordance avec le fichier web, avec métriques clés et implication immédiate

» id_web manquant

- » 94 lignes avec id_web vide dans fichier_liaison.xlsx
Produit présent en ERP mais sans correspondance web renseignée Premier point d'alerte majeur à traiter

» id_web introuvable

- » 19 lignes où id_web ne correspond à aucun sku produit dans le fichier web Causes possibles: produit web supprimé, SKU modifié ou liaison obsolète Vérifier formes non standard du produit web

» Doublons product_id

- » Aucun doublon détecté sur product_id dans la table de liaison Relation ERP vers liaison: 1 produit ERP = 1 ligne de liaison

Anomalies détectées dans la liaison - part2

19 lignes avec id_web renseigné mais introuvable dans le fichier web;
aucun doublon sur product_id, relation ERP vers liaison: 1 produit
ERP = 1 ligne de liaison

» Incohérences id_web

» 19 lignes où id_web ne correspond à aucun sku produit dans le fichier web

» Causes possibles:

- 1 produit web supprimé,
- 2 SKU modifié,
- 3 table de liaison obsolète,
- 4 ou format non standard

» Intégrité product_id

» Aucun doublon détecté sur product_id dans la table de liaison Relation ERP to liaison confirmée: 1 produit ERP = 1 ligne de liaison

Anomalies dans le fichier web

Détecter et filtrer les lignes non produits, corriger SKU manquants ou non numériques, et résoudre les doublons pour un rapprochement automatique fiable

- » Fichier non propre
 - » Contient produits, attachment et lignes incomplètes.
 - » Il faut filtrer `post_type = product` avant toute analyse métier
- » SKU manquants ou erronés
 - » 2 produits sans SKU détectés 4 produits avec SKU non numérique Exemples: '13127-1', 'bon-cadeau-25-euros', SKU vide
 - » Problème: liaison utilise `id_web` comme clé numérique
- » Doublons SKU
 - » 4 lignes produit problématiques: doublons ou SKU non exploitables Impact: sku est la clé cible de la liaison

Anomalies détectées dans le fichier ERP

Résumé des incohérences critiques et éléments fragiles à corriger :
prix et stock négatifs, statuts et quantités divergents, correspondances
web manquantes ou invalides

» Prix négatifs

- » 2 produits avec prix négatif — valeur aberrante probable Cas métier possibles : avoir, article de correction, remise modélisée comme produit Sinon action requise : corriger en priorité

» Stock négatif

- » 2 produits avec stock négatif — à contrôler Peut résulter du stock théorique passant sous zéro dans l'ERP Vérifier règles de gestion et synchronisation

» Incohérences statut/quantité

- » 1 produit en instock avec quantité moins or equal to 0 5 produits en outofstock avec quantité greater than 0 Indique statut non recalculé, mauvaise synchro ou règle métier non documentée

» Aspects sains

- » Structure des 3 fichiers globalement cohérente Table de liaison fonctionne et pas de doublon de product_id Clé de passage confirmée : id_web to sku

» Points fragiles

- » 94 produits ERP sans identifiant web 19 correspondances web invalides Fichier web contenant beaucoup de bruit technique et SKU non standards Valeurs aberrantes détectées : prix négatifs, stock négatif, incohérences

Constats clés sur la qualité des fichiers

Bilan intermédiaire : points sains identifiés et risques à traiter, avec chiffres précis pour priorisation des actions

- » Structure générale
 - » Les 3 fichiers sont globalement cohérents en structure La table de liaison joue correctement son rôle de correspondance La clé de passage semble être id_web to sku (liaison stable)
- » Points sains
 - » Aucun doublon de product_id dans la table de liaison
- » Risques majeurs
 - » 94 produits ERP sans identifiant web
 - » 19 correspondances web invalides à corriger ou revalider
- » Bruit et incohérences
 - » Le fichier web contient beaucoup de bruit technique impactant la qualité Certains SKU web sont vides, textuels ou non standards Valeurs ERP aberrantes: prix négatifs, stock négatif, statut/quantité incohérents

Risque principal: rapprochement ERP et Web

Construire un jeu de contrôle avant toute synchronisation pour détecter produits absents, liens invalides et cas web non standard

- » produits ERP sans correspondance web
- » correspondances obsolètes
- » SKU web non normalisés
- » produits web spéciaux hors logique standard
- » jeu de contrôle avec 4 statuts:
 - 1 lié correctement,
 - 2 absent du web,
 - 3 lien invalide,
 - 4 web non standard
- » prioriser ce contrôle avant toute synchronisation ou audit métier

C:\Users\karap\OpenClassRooms\projet10\data\projet10\nettoyage_reconciliation_DuckDB.py

Script de démonstration pour une automatisation

Un script pilote d'automatisation ; nettoyage_reconciliation_DuckDB.py

Architecture modulaire en 6 phases couvrant ingestion, nettoyage par source, fusion, scoring, synthèse et export des résultats

Ingestion

Vérification des fichiers ERP WEB
LIAISON, chargement Excel en Pandas,
initialisation DuckDB et tables de staging
brutes

Scores et segmentation

Calcul du chiffre d'affaires par produit,
statistiques de prix, z-scores, détection
outliers et segmentation premium vs
ordinaires

Fusion et jointure

Contrôle de cohérence des jointures,
création des liaisons valides et fusion
finale ERP LIAISON WEB

Traitement par source

Contrôle des doublons globaux;
nettoyage, dédoublonnage et tests qualité
pour ERP, WEB et LIAISON

Génération du résumé

Compilation des métriques finales et
affichage du résumé complet du
workflow

Export externe

Export consolidation et CA par produit en
Excel; export vins premium et vins
ordinaires en CSV

Workflow data DuckDB modulaire

Phases séquentielles avec trois branches ERP, WEB et LIAISON parallélisées, contrôle qualité systématique et export des livrables



Tests et qualité des données

Vérifications automatiques en script: assertions à l'exécution pour assurer intégrité, correspondances et scores selon règles définies

ERP tests

- » Aucun doublon sur product_id
- » Pas de valeurs NULL critiques price et product_id
- » Avertissement sur prix négatifs

WEB tests

- » Aucun doublon sur sku
- » Produits uniquement post_type = 'product' SKU non NULL et non vides

Liaison

- » Aucun doublon sur product_id
- » Pas de valeurs NULL product_id et id_web

Fusion

- » Toutes les liaisons ont correspondance ERP Toutes les liaisons ont correspondance WEB
Nombre consolidé = nombre de liaisons valides

Tests des scores

- » CA toujours positif
- » Segmentation complète premium plus ordinaires = total Vins premium: z-score over 2 et prix over borne IQR

Détection des vins premium

Méthodes statistiques complémentaires pour repérer les prix anormalement élevés dans la gamme, avec classification finale selon la robustesse des signaux

- » Objectif : Identifier les vins dont le prix est anormalement élevé par rapport à la gamme
- » Méthode Z-score
 - » $z = (\text{prix} - \text{moyenne}) / \text{écart-type}$; Un vin premium si son z-score est plus grand que 2
- » Méthode IQR
 - » Q1 = 25% prices, Q3 = 75% prices, IQR = Q3 - Q1 Seuil haut = Q3 + 1.5 × IQR; premium si prix plus grand que le seuil haut
- » Classification finale
 - » PREMIUM_BOTH: détecté par les deux méthodes (très fiable) PREMIUM_ZSCORE_ONLY, PREMIUM_IQR_ONLY, STANDARD
- » Pourquoi deux méthodes
 - » Z-score sensible aux valeurs extrêmes IQR robuste et moins influencé par les outliers Combinaison offre détection plus fiable des vins premium
 - » Un vin premium = statistiquement atypique vers le haut Détection basée sur la distribution des prix, pas sur une règle arbitraire

Fichiers générés clés

Inventaire des livrables DuckDB et Pandas avec contenu et rôles pour vérification rapide des tables finales, exports CA et listes vins premium/ordinaires

Version DuckDB

- » projet_consolidation_duckdb.duckdb: base DuckDB avec staging, nettoyage, fusion, scores et tables finales
- » consolidation_duckdb.xlsx: table finale consolidée ERP + LIAISON + WEB, 1 ligne = 1 produit consolidé
- » ca_par_produit_duckdb.xlsx: chiffre d'affaires par produit (product_id, sku, post_title, prix_unitaire, quantite_vendue, chiffre_affaires)
- » vins_premium_duckdb.csv et vins_ordinaires_duckdb.csv: sous-ensembles premium (z-score prix over 2 et prix au-dessus de l'IQR) et non premium

Version Pandas

- » consolidation.xlsx: table finale consolidée ERP + LIAISON + WEB (mêmes colonnes que version DuckDB)
- » ca_par_produit.xlsx: chiffre d'affaires par produit (mêmes colonnes que version DuckDB)
- » vins_premium.csv et vins_ordinaires.csv: sous-ensembles produits classés premium et non premium

Exemple de sortie

PHASE 1
ERP chargé : 825 lignes, 5 colonnes
WEB chargé : 1513 lignes, 28 colonnes
LIAISON chargée : 825 lignes, 2 colonnes

PHASE 2 : TRAITEMENT DES DONNÉES INDIVIDUELLES CONTRÔLE DES DOUBLONS
Nombre de clés ERP dupliquées sur product_id : 0
Nombre de SKU WEB dupliqués sur les produits : 1
Nombre de product_id dupliqués dans la liaison : 0

TRAITEMENT ERP Nombre de lignes ERP après nettoyage : 825
Prix négatifs dans ERP nettoyé : 2 Stocks négatifs dans ERP nettoyé : 2
→ Tests de qualité ERP...
⚠ Avertissement : 2 prix négatifs détectés (accepté pour analyse)
✅ Tests ERP passés

TRAITEMENT WEB Après nettoyage du fichier web : 714 lignes
Après dédoublonnage du fichier web : 714 lignes
Total_sales négatifs dans WEB nettoyé : 0
→ Tests de qualité WEB...
✅ Tests WEB passés

TRAITEMENT LIAISON
Nombre de lignes LIAISON après nettoyage : 734
→ Tests de qualité LIAISON...
✅ Tests LIAISON passés

PHASE 3 : FUSION ET JOINTURE
CONTRÔLE DE COHÉRENCE DES JOINTURES
Lignes de liaison sans correspondance ERP : 0
Lignes de liaison sans correspondance WEB : 20
Nombre de lignes de liaison valides : 714

FUSION FINALE
Nombre total de lignes dans produits_consolides : 714
→ Tests de qualité de fusion...
✅ Tests de fusion passés

PHASE 4 : SCORES ET SEGMENTATION
CALCUL DU CHIFFRE D'AFFAIRES Nombre de lignes dans ca_par_produit : 714 Chiffre d'affaires global : 70568.60
DéTECTION DES VINS PREMIUM Nombre de vins premium : 30 Nombre de vins ordinaires : 684
→ Tests de qualité des scores...
✅ Tests des scores passés

PHASE 5 : GÉNÉRATION DU RÉSUMÉ


RÉSUMÉ FINAL

Workflow DuckDB terminé avec succès.

- Lignes ERP nettoyées : 825
- Lignes WEB nettoyées : 714
- Lignes LIAISON valides : 714
- Lignes consolidées : 714
- Chiffre d'affaires global : 70568.60
- Nombre de vins premium : 30
- Nombre de vins ordinaires : 684

Kestra

http://localhost:8080/ui/main/flows/edit/open_class_room.kestra/orchestration_vins_ducko



Kestra · interface

L’interface web de Kestra est assez intuitive et organisée autour de 4 vues principales :

1. Dashboard / Executions

- * Liste des exécutions de workflows
- * Statut (SUCCESS, FAILED, RUNNING)
- * Accès rapide aux logs et détails

2. Flows

- * Catalogue de tous les workflows YAML
- * Classés par namespace
- * On peut créer, éditer et versionner tes flows directement ici


3. Topology (très important)

- * Vue graphique du workflow
- * Chaque tâche est un bloc (comme notre pipeline ERP / WEB / LIAISON)
- * On voit les dépendances et le parallélisme
- * On peut cliquer sur chaque tâche pour voir logs + outputs

4. Gantt

- * Vue temporelle de l’exécution
- * Chaque tâche apparaît avec sa durée
- * Très utile pour voir :
 - * le parallélisme
 - * les tâches lentes
 - * les retries

👉 En résumé :
* **Flows** = création
* **Topology** = logique du pipeline
* **Gantt** = performance / exécution
* **Executions** = historique
C’est pour cela que YAML a été structuré avec des tâches de tests séparées : on les voit clairement dans **Topology + Gantt**, comme un vrai pipeline data pro.



“On ne fait pas qu’orchestrer des traitements, on garantit la qualité des données et on détecte les écarts métier automatiquement.”

Kestra : vue topology

🔄 Pipeline end-to-end automatisé

1. Ingestion & contrôles

- ✓ Validation des fichiers
- ✓ Détection des doublons

2. Traitement parallèle ⚡ ERP | WEB | LIAISON nettoyés en simultané

3. Data Quality intégrée ✓ Tests doublons

- ✓ Tests valeurs manquantes
- ✓ Tests cohérence jointures

4. Transformation métier

- 💰 Calcul du chiffre d’affaires
- 📊 Détection des vins premium (Z-score)

5. Validation & industrialisation

- 🔧 Tests automatisés (pytest)
- 📈 Dashboard final0


📊 Résultat clé

✓ Données conformes aux attentes

🎯 Valeur ajoutée

👍 Pipeline **fiable, scalable et orienté qualité**

👍 Détection automatique des anomalies métier



La vue **Gantt** met en évidence l’enchaînement temporel du workflow et montre très clairement la logique d’exécution choisie.

- Au début, on observe une phase **séquentielle de contrôle d’entrée** avec :
- * ``validate_inputs``, qui vérifie la présence et la lisibilité des trois fichiers source,
 - * ``test_input_files``, qui valide leur conformité,
 - * ``global_duplicate_scan``, qui réalise un premier contrôle global des doublons.
- Ensuite, le workflow entre dans une phase de **parallélisation**, visible avec le bloc ``parallel_cleaning``, qui lance en même temps :
- * ``clean_erp``
 - * ``clean_web``
 - * ``clean_liaison``

Cette parallélisation est importante car elle réduit le temps global d’exécution et reflète bien l’architecture modulaire du pipeline.

Une fois les trois branches terminées, on voit apparaître le bloc ``tests_quality``, lui aussi structuré de manière lisible dans le Gantt. Il regroupe les tests fonctionnels essentiels :


- * ``test_absence_doublons``
 - * ``test_absence_valeurs_manquantes``
- On passe ensuite à la phase de **réconciliation et de fusion**, avec :
- * ``test_join_coherence``, qui contrôle la qualité des correspondances entre ERP, WEB et LIAISON,
 - * ``create_valid_links``, qui ne conserve que les liaisons valides,
 - * ``merge_final``, qui produit la table consolidée finale.

Puis viennent les traitements analytiques :

- * ``compute_ca``, pour le calcul du chiffre d’affaires,
- * ``test_ca_coherence``, pour vérifier la cohérence des montants,
- * ``zscore_segmentation``, pour détecter les vins premium via le z-score,
- * ``test_zscore_prix``, pour valider la cohérence statistique de cette segmentation.

Enfin, la fin du workflow est dédiée à la **validation globale et à la restitution** :

- * ``pytest_parallel``, qui exécute des tests complémentaires automatisés,
- * ``summary_dashboard``, qui centralise les métriques finales,
- * ``export_outputs``, qui génère les livrables,
- * ``end``, qui marque la fin correcte du traitement.



Fin

Conclusion et Démonstration

Prêt pour le prochain COPIL chez BottleNeck

