

diagramme d'architecture d'automatisation

Description du workflow automatisé

Diagramme d'architecture d'automatisation de données avec une lecture de gauche à droite ou de haut en bas.

Le workflow représente un traitement mensuel de consolidation de données produit entre un système ERP, un CMS web et un fichier de correspondance.

Le workflow est déclenché automatiquement **tous les 15 du mois à 9h00**.

Le planificateur peut être représenté comme un scheduler de type **EventBridge Scheduler, cron, Airflow scheduler** ou équivalent.

Le point de départ du workflow est un bucket **Amazon S3** contenant trois fichiers déposés en entrée :

- Fichier_erp.xlsx
- Fichier_web.xlsx
- fichier_liaison.xlsx

Ces trois fichiers sont récupérés par une tâche d'ingestion.

Juste après cette réception, ajouter une tâche de test nommée **Test de présence et de conformité des fichiers d'entrée**.

Cette tâche vérifie :

- que les 3 fichiers attendus sont bien présents dans S3
- que les noms sont exacts
- que le format est bien .xlsx
- que les fichiers ne sont pas vides
- que les colonnes minimales attendues existent

Si ce test échoue, le workflow s'arrête et envoie une alerte d'échec.

Branche 1 : traitement du fichier ERP

La tâche nommée **Chargement du fichier ERP** lit le fichier ERP et charge les données dans une zone de travail temporaire.

La tâche **Nettoyage ERP** applique les traitements suivants :

- contrôle des doublons
- contrôle des valeurs manquantes
- contrôle des types attendus
- suppression des lignes dupliquées
- suppression des lignes avec valeurs manquantes ou mauvaises valeurs
- conservation uniquement des lignes exploitables

Juste après, la tâche de test nommée **Test qualité ERP** vérifie :

- absence de doublons sur `product_id`
- absence de valeurs manquantes sur les colonnes critiques
- conformité des types numériques sur `product_id`, `onsale_web`, `price`, `stock_quantity`
- présence de `stock_status`
- nombre de lignes après nettoyage cohérent et non nul

Si le test ERP échoue, envoyer une alerte et arrêter le workflow.

Branche 2 : traitement du fichier WEB

La tâche nommée **Chargement du fichier WEB** lit le fichier web depuis S3.

La tâche **Nettoyage WEB** applique les opérations suivantes :

- filtrage des lignes pour ne conserver que `post_type = product`
- contrôle des doublons
- contrôle des valeurs manquantes
- contrôle des types attendus
- suppression des lignes dupliquées
- suppression des lignes avec valeurs manquantes ou mauvaises valeurs
- déduplication sur `sku`

La tâche de test nommée **Test qualité WEB** vérifie :

- absence de doublons sur `sku`
- présence des colonnes critiques comme `sku`, `post_title`, `total_sales`
- absence de mauvaises valeurs sur les colonnes numériques comme `total_sales`
- présence d'un nombre de lignes produits cohérent et non nul après nettoyage

Si le test WEB échoue, envoyer une alerte et arrêter le workflow.

Branche 3 : traitement du fichier de liaison

La tâche nommée **Chargement du fichier de liaison** lit le fichier de jonction entre ERP et web.

La tâche **Nettoyage du fichier de liaison** applique :

- contrôle des doublons
- contrôle des valeurs manquantes

- contrôle des types attendus
- suppression des lignes dupliquées
- suppression des lignes avec `product_id` ou `id_web` manquants
- conservation uniquement des lignes propres

La tâche de test nommée **Test qualité liaison** vérifie :

- absence de doublons sur `product_id`
- absence de valeurs manquantes sur `product_id` et `id_web`
- cohérence des types
- nombre de lignes après nettoyage cohérent et non nul

Si le test de liaison échoue, envoyer une alerte et arrêter le workflow.

Étape de réconciliation

Une fois les trois branches validées, la tâche centrale nommée **Contrôle de cohérence des jointures** compare :

- les `product_id` du fichier de liaison avec les `product_id` ERP nettoyés
- les `id_web` du fichier de liaison avec les `SKU` du fichier web nettoyé

Elle identifie :

- les lignes de liaison sans correspondance ERP
- les lignes de liaison sans correspondance WEB
- les mauvaises jointures

La tâche de test nommée **Test de validité des correspondances** vérifie :

- qu’aucune jointure invalide n’est conservée
- que le nombre de lignes valides est cohérent
- que la table de liaison finale est exploitable pour la fusion

Si ce test échoue, une alerte est envoyée et le workflow est arrêté.

Étape de fusion

La tâche nommée **Fusion des données ERP + LIAISON + WEB** effectue les jointures correctes entre les trois jeux de données nettoyés et produit une table consolidée.

Juste après, ajouter une tâche de test nommée **Test de cohérence de la consolidation** vérifie :

- que le nombre de lignes fusionnées est cohérent
- qu’aucune ligne consolidée ne contient de jointure cassée
- que les colonnes métier attendues sont présentes
- que la consolidation finale n’est pas vide

Si ce test échoue, une alerte est envoyée et le workflow est arrêté

Étape d’agrégation métier

La tâche **Calcul du chiffre d’affaires** calcule :

- le chiffre d’affaires par produit
- le chiffre d’affaires total

La règle de calcul est : **CA produit = price × total_sales**

Juste après, la tâche de test nommée **Test de cohérence du chiffre d’affaires** vérifie :

- absence de prix négatifs pour les lignes utilisées
- absence de ventes négatives
- absence de valeurs nulles dans les champs nécessaires au calcul
- cohérence du nombre de lignes retenues pour le calcul
- cohérence du total agrégé

Si ce test échoue, une alerte est envoyée et le workflow est arrêté.

Étape d'analyse statistique

La tâche **Détection des vins premium** applique deux méthodes statistiques sur le prix :

- le **z-score**
- l'**intervalle interquartile (IQR)**

Elle classe les produits en :

- vins premium
- vins ordinaires

Juste après, la tâche de test nommée **Test statistique premium** vérifie :

- que le z-score a bien pu être calculé
- que l'écart-type n'est pas nul
- que les bornes IQR sont cohérentes
- que le nombre de vins premium détectés est plausible et non nul si la distribution le permet

Si ce test échoue, une alerte est détectée et le workflow est arrêté.

Étape de génération des livrables

La tâche **Production des fichiers de sortie** génère :

- consolidation.xlsx
- ca_par_produit.xlsx
- vins_premium.csv
- vins_ordinaires.csv

Ces fichiers sont déposés dans un bucket S3 de sortie, par exemple :

- s3://bucket-output/consolidation/
- s3://bucket-output/reporting/
- s3://bucket-output/premium/

Une tâche de test nommée **Test de présence et d'intégrité des livrables** qui vérifie :

- que les 4 fichiers ont bien été générés
- qu'ils ne sont pas vides
- que les feuilles Excel attendues existent
- que les CSV contiennent des lignes
- que les nombres de lignes sont cohérents avec les résultats du traitement

Si ce test échoue, une alerte est envoyées et le workflow est marqué en échec.

Étape finale

La tâche **Journalisation et notification finale** enregistre :

- la date d'exécution
- le nombre de lignes ERP nettoyées
- le nombre de lignes WEB nettoyées
- le nombre de lignes de liaison valides
- le nombre de lignes consolidées
- le chiffre d'affaires total
- le nombre de vins premium
- le statut final du workflow

Puis elle envoie :

- une notification de succès si tout est correct
- ou une notification d'échec si une étape de test a bloqué le traitement

Planification

Un bloc séparé **Planification** est ajouté et relié au début du workflow avec le libellé :

Exécution automatique tous les 15 du mois à 09:00

Expression :

- cron mensuel : 0 9 15 * *


Le scheduler déclenche le workflow complet de bout en bout.

Représentation visuelle

Le diagramme fait apparaître :

- un **scheduler** en haut
- un bloc **S3 fichiers d'entrée**
- trois branches parallèles :
 - nettoyage ERP + test ERP
 - nettoyage WEB + test WEB
 - nettoyage Liaison + test Liaison
- une convergence vers :
 - contrôle des jointures + test
 - fusion + test
 - calcul CA + test
 - détection premium + test
 - génération des livrables + test
 - journalisation / notification

Les tâches de test sont présentées comme des blocs distincts, idéalement de couleur différente, pour montrer qu'après **chaque transformation**, un **contrôle qualité automatique** est exécuté.



Version compacte à donner telle quelle à un outil de diagramme

Créer un diagramme de workflow data automatisé mensuel.

Départ avec un scheduler qui exécute le workflow tous les 15 du mois à 9h00.

Le scheduler déclenche la réception de trois fichiers déposés dans S3 : Fichier_erp.xlsx, Fichier_web.xlsx et fichier_liaison.xlsx.

Ajouter un premier test de présence et de conformité des fichiers.

Ensuite créer trois branches parallèles.

Branche 1 : chargement ERP, nettoyage ERP, test qualité ERP.

Branche 2 : chargement WEB, filtrage des produits, nettoyage WEB, test qualité WEB.

Branche 3 : chargement fichier de liaison, nettoyage liaison, test qualité liaison.

Les trois branches convergent vers un contrôle de cohérence des jointures, puis un test de validité des correspondances.

Ensuite ajouter la fusion ERP + liaison + WEB, puis un test de cohérence de la consolidation.

Puis ajouter le calcul du chiffre d'affaires par produit et du chiffre d'affaires total, suivi d'un test de cohérence du chiffre d'affaires.

Ensuite ajouter la détection des vins premium avec z-score et IQR, suivie d'un test statistique premium.

Puis ajouter la génération des fichiers de sortie consolidation.xlsx, ca_par_produit.xlsx, vins_premium.csv et vins_ordinaires.csv dans S3.

Ajouter un test final de présence et d'intégrité des livrables.

Terminer par une tâche de journalisation et une notification de succès ou d'échec.

Représenter visuellement les tâches de test comme des contrôles qualité distincts à chaque étape du workflow.

Si tu veux, je peux aussi te le convertir directement en **pseudo-Mermaid** ou en **squelette Lucidchart encore plus court**.