

Diagramme d'architecture d'automatisation

Voici une description **d'architecture**. Je l'ai aligné sur la structure réelle de mon workflow DuckDB : ingestion, traitements parallèles ERP/WEB/LIAISON, convergence vers la fusion, calculs analytiques, segmentation, exports, avec **tests explicites à chaque étape**

Le diagramme de workflow data modulaire, est organisé en **phases séquentielles**, avec une lecture de gauche à droite ou de haut en bas. Le workflow montre une **architecture de traitement de données avec DuckDB**, structurée autour de plusieurs phases successives, avec **trois branches parallèles de traitement** pour les sources ERP, WEB et LIAISON, puis une convergence vers les étapes de réconciliation, d'analyse métier et d'export.

Phase 1 — Ingestion des données

Dans cette phase, doit afficher les trois fichiers d'entrée :

- fichier ERP
- fichier WEB
- fichier LIAISON

Ces trois fichiers sont lus par le workflow et chargés dans une couche de staging DuckDB.

Vient ensuite une tâche de **vérification des fichiers d'entrée**.

Cette tâche de test doit vérifier :

- que les trois fichiers attendus sont présents
- que leur format est correct

- qu'ils sont lisibles
- qu'ils peuvent être chargés dans les tables de staging

Si le test échoue, le workflow s'arrête avec une erreur.

Si le test réussit, le workflow passe à la phase suivante.

Phase 2 — Traitement des données individuelles

Cette phase commence par un bloc commun nommé **Contrôle global des doublons**, qui vérifie la présence de doublons sur les clés principales dans les trois sources :

- clé produit côté ERP
- clé produit côté WEB
- clé de rattachement côté LIAISON

Après ce bloc, le workflow se divise en **trois branches parallèles** :

Branche ERP

Une tâche nommée **Traitement ERP**.

Cette tâche effectue :

- typage des colonnes
- conversion des colonnes numériques
- normalisation des champs texte
- suppression des valeurs nulles critiques
- suppression des enregistrements invalides
- dédoublonnage par identifiant produit

Juste après, vient un bloc de test nommé **Tests de qualité ERP**.

Ces tests vérifient :

- absence de doublons sur l'identifiant produit
- absence de valeurs nulles sur les colonnes critiques
- cohérence des types
- contrôle des valeurs anormales comme les prix négatifs ou les stocks négatifs

Un prix négatif par exemple déclenche un **avertissement**, sans forcément bloquer l'analyse.

Branche WEB

Soit la tâche nommée **Traitement WEB**.

Cette tâche effectue :

- filtrage pour ne conserver que les produits
- typage des colonnes
- nettoyage des champs texte
- suppression des valeurs nulles critiques
- suppression des lignes invalides
- dédoublonnage sur le SKU

Juste après, vient un bloc de test nommé **Tests de qualité WEB**.

Ces tests vérifient :

- absence de doublons sur le SKU
- présence exclusive de lignes de type produit

- absence de SKU vide
- cohérence des ventes et des champs clés

Branche LIAISON

On a une tâche nommée **Traitement LIAISON**.

Cette tâche effectue :

- typage des identifiants
- nettoyage des identifiants de jointure
- suppression des valeurs nulles
- suppression des lignes invalides
- dédoublonnage sur l'identifiant produit

Juste après, s'affiche un bloc de test nommé **Tests de qualité LIAISON**.

Ces tests vérifient :

- absence de doublons sur l'identifiant produit
- absence de valeur nulle dans les clés de jointure
- cohérence des identifiants de rapprochement

Les trois branches **convergent** vers la phase suivante.

Phase 3 — Fusion et jointure

Cette phase commence par une tâche nommée **Contrôle de cohérence des jointures**.

Cette tâche vérifie :

- que chaque ligne de liaison a une correspondance dans les données ERP nettoyées
- que chaque ligne de liaison a une correspondance dans les données WEB nettoyées
- que seules les liaisons valides sont conservées

On a ensuite une tâche nommée **Création des liaisons valides**. Puis une tâche nommée **Fusion finale des données**.

Cette fusion combine :

- les données ERP nettoyées
- les liaisons valides
- les données WEB nettoyées

La sortie de cette phase est une table consolidée unique par produit.

Juste après, on trouve un bloc de test nommé **Tests de qualité de fusion**.

Ces tests vérifient :

- que toutes les lignes fusionnées possèdent une correspondance ERP valide
- que toutes les lignes fusionnées possèdent une correspondance WEB valide
- que le nombre de lignes consolidées est cohérent avec le nombre de liaisons valides
- que la table consolidée n'est pas vide

Si ces tests passent, le workflow continue.

Phase 4 — Scores et segmentation

Cette phase contient deux sous-étapes principales.

Sous-étape 1 — Calcul du chiffre d'affaires

Cette tâche calcule :

- le chiffre d'affaires par produit
- le chiffre d'affaires global

Le calcul repose sur :

- le prix unitaire
- la quantité vendue

Juste après, doit afficher un bloc de test nommé **Tests de cohérence du chiffre d'affaires**.

Ces tests vérifient :

- absence de chiffre d'affaires négatif
- présence des données nécessaires au calcul
- cohérence des montants calculés
- validité de l'agrégation globale

Sous-étape 2 — Détection des vins premium

Cette tâche applique une logique statistique sur le prix :

- calcul de la moyenne
- calcul de l'écart-type
- calcul des quartiles
- calcul du z-score
- calcul de la borne haute IQR

- segmentation en vins premium et vins ordinaires

Juste après, On affiche un bloc de test nommé **Tests de qualité des scores**.

Ces tests vérifient :

- que les scores statistiques sont calculables
- que les produits classés premium respectent bien les règles de segmentation
- que la segmentation couvre tous les produits
- que la somme des vins premium et des vins ordinaires est cohérente avec l'ensemble analysé

Phase 5 — Génération du résumé

Cette phase compile les métriques finales du workflow :

- état du traitement ERP
- état du traitement WEB
- état du traitement LIAISON
- état de la fusion
- résultat du calcul du chiffre d'affaires
- résultat de la segmentation premium

Cette phase est représentée comme une étape de **synthèse et de contrôle final**.

Phase 6 — Export des livrables

Créer une **Phase 6 : Export des fichiers externes**.

Cette phase génère les livrables suivants :

- un fichier Excel de consolidation
- un fichier Excel du chiffre d'affaires par produit
- un fichier CSV des vins premium
- un fichier CSV des vins ordinaires

Juste après, on trouve un bloc de test nommé **Tests d'intégrité des exports**.

Ces tests vérifient :

- que chaque fichier est bien créé
- que les fichiers ne sont pas vides
- que les colonnes attendues sont présentes
- que les fichiers premium et ordinaires sont cohérents avec la segmentation calculée

Gestion des erreurs et fin du workflow

On a aussi une logique transversale de contrôle d'erreur :

- si un test échoue, le workflow s'arrête
- un message d'erreur explicite est produit
- la phase en échec est identifiable

Si tous les tests passent, le workflow se termine par un bloc final : **Traitement terminé avec succès**

